

Universidad del Valle de Guatemala

Facultad de Ingeniería
Departamento de Ciencias de la Computación

CC3084 — Data Science
Semestre II, 2026

Laboratorio 5

Clasificación de tweets usando minería de texto

Integrantes del grupo

Anggie Quezada Iris Ayala Jonathan Díaz

29 de agosto de 2026

Informe y repositorio: <https://github.com/Qu3zada22/lab5-ds>

Índice

1. Introducción	1
2. Objetivo	1
3. Datos y alcance del análisis	1
3.1. Origen y tamaño	1
3.2. Balance y valores ausentes	2
4. Metodología reproducible	2
5. Limpieza y preprocesamiento	3
5.1. Texto para clasificación temática	3
5.2. Texto para sentimiento	3
6. Análisis exploratorio	3
6.1. Frecuencias y vocabulario compartido	3
6.2. Nubes de palabras	5
7. Unigramas, bigramas y trigramas	5
8. Modelos de clasificación	7
8.1. Configuración	7
9. Función de clasificación	7
10. Sentimiento con VADER	8
11. Extremos de sentimiento y comparación por categoría	8
11.1. Diez tweets más negativos	8
11.2. Diez tweets más positivos	9
11.3. ¿Los tweets de desastre son más negativos?	9
12. Reentrenamiento con negatividad	10
13. Limitaciones	10
14. Conclusiones	11
A. Reproducibilidad	12

1. Introducción

Se construyó un flujo reproducible para clasificar tweets en inglés como referencias a un desastre real (**target=1**) o usos no literales y conversaciones ordinarias (**target=0**). El análisis supervisado utiliza los 7,613 registros de entrenamiento de la competencia de Kaggle. Se normalizó el texto para el análisis temático, se estudiaron frecuencias y n-gramas dentro de cada tweet, y se compararon Naive Bayes multinomial, regresión logística y una máquina de soporte vectorial lineal sobre TF-IDF de unigramas y bigramas.

La regresión logística obtuvo el mejor equilibrio en prueba: exactitud 0.822718 y F1 0.776490. El análisis de sentimiento se realizó separadamente sobre el texto original mediante VADER, para conservar puntuación, mayúsculas y emoticones. Los tweets de desastre presentaron una negatividad media mayor (0.173582 frente a 0.132318), pero el efecto rango-biserial fue pequeño (0.1465). Agregar la negatividad como característica no mejoró el clasificador: el F1 disminuyó a 0.775104 ($\Delta = -0.001386$). En consecuencia, el producto final conserva la regresión logística basada exclusivamente en TF-IDF.

2. Objetivo

El objetivo general fue desarrollar y evaluar un sistema reproducible que reciba un tweet sin preprocesar y determine si describe un desastre real. Para ello se buscó: (i) comprender la calidad, balance y vocabulario del conjunto; (ii) documentar la limpieza; (iii) estudiar unigramas, bigramas y trigramas; (iv) comparar clasificadores mediante métricas apropiadas; (v) analizar sentimiento y negatividad; y (vi) comprobar empíricamente si la negatividad aporta señal predictiva adicional.

3. Datos y alcance del análisis

3.1. Origen y tamaño

Los datos proceden de la competencia *Natural Language Processing with Disaster Tweets* de Kaggle [1]. La consigna indica “más de 10,500 filas” porque la entrega de Kaggle comprende 7,613 filas etiquetadas en **train.csv** y 3,263 filas sin etiqueta en **test.csv**, es decir, 10,876 registros en conjunto. El presente análisis supervisado usa únicamente **train.csv**, porque es el archivo que contiene la variable objetivo y el solicitado expresamente para entrenamiento y evaluación.

Cuadro 1: Variables del conjunto de entrenamiento.

Variable	Descripción	Tipo observado
id	Identificador del tweet.	Entero
keyword	Palabra clave asociada; puede estar ausente.	Texto
location	Ubicación declarada por el usuario; puede estar ausente y no está normalizada.	Texto
text	Contenido original del tweet.	Texto
target	Clase: 1 para desastre real y 0 para no desastre.	Entero binario

3.2. Balance y valores ausentes

El conjunto presenta un desbalance moderado, no extremo: 4,342 tweets no asociados con desastres y 3,271 asociados con desastres. Por ello se usó estratificación y se priorizó F1, sin limitar la evaluación a exactitud.

Cuadro 2: Distribución de la variable objetivo.

Categoría	Frecuencia	Porcentaje
No desastre (0)	4,342	57.03 %
Desastre real (1)	3,271	42.97 %
Total	7,613	100.00 %

No existen nulos en `text`, `target` ni `id`. `keyword` tiene 61 ausencias (0.80 %) y `location`, 2,533 (33.27 %). La segunda variable es además texto libre y heterogéneo, por lo que no se imputó ni incorporó al modelo principal. Esta exclusión evita imponer una interpretación geográfica falsa, aunque también deja señal potencial sin explorar.

4. Metodología reproducible

El trabajo se ejecutó con `uv 0.11.28`, Python 3.9.25 y JupyterLab. El entorno bloqueado contiene `pandas 2.3.3`, `NumPy 2.0.2`, `scikit-learn 1.6.1`, `SciPy 1.13.1`, `NLTK 3.9.2`, `Matplotlib 3.9.4` y `wordcloud 1.9.6`. Las restricciones directas están declaradas en `pyproject.toml` y la resolución exacta en `uv.lock`.

El protocolo experimental fue el siguiente:

1. cargar los 7,613 registros etiquetados y auditar esquema, nulos y balance;
2. construir `text_cleaned` para análisis léxico y clasificación temática;
3. separar una sola vez 80 % para entrenamiento (6,090 tweets) y 20 % para prueba (1,523), con `random_state=42` y `stratify=y`;
4. ajustar TF-IDF únicamente sobre entrenamiento, con unigramas y bigramas y un máximo de 5,000 características;
5. entrenar y comparar tres clasificadores sobre exactamente el mismo split;
6. calcular VADER sobre `text` original y reutilizar los mismos índices para evaluar la característica `negativity`, sin reajustar TF-IDF con prueba.

Las nubes de palabras usan también semilla 42. El notebook descargó de NLTK los recursos `stopwords` y `vader_lexicon` cuando no estaban disponibles. Los comandos completos se incluyen en el anexo de reproducibilidad.

5. Limpieza y preprocesamiento

5.1. Texto para clasificación temática

La función `limpiar_tweet` aplica las transformaciones en un orden fijo:

1. convierte a minúsculas;
2. elimina URLs con expresiones regulares;
3. elimina menciones completas de la forma `@usuario`;
4. elimina el símbolo `#`, pero conserva la palabra del hashtag;
5. elimina todos los dígitos;
6. conserva solo letras inglesas y espacios, con lo cual elimina puntuación, apóstrofes, caracteres especiales y emoticones;
7. normaliza espacios y elimina las *stopwords* inglesas de NLTK.

La decisión sobre números es deliberadamente simplificadora: la expresión `\d+` elimina también 911. Esto reduce variantes y ruido, pero puede descartar una señal relevante de emergencia; debe considerarse una limitación y una hipótesis para trabajo posterior. Ningún registro quedó vacío. Por ejemplo, “Our Deeds are the Reason of this #earthquake May ALLAH Forgive us all” se transforma en “deeds reason earthquake may allah forgive us”.

5.2. Texto para sentimiento

La limpieza temática no se reutilizó para VADER. El sentimiento se calculó sobre `text` original porque VADER fue diseñado para redes sociales y sus reglas consideran mayúsculas, signos de exclamación, puntuación, negaciones, intensificadores y emoticones [2, 3]. Esta separación evita destruir información afectiva al mismo tiempo que mantiene una representación temática más compacta para TF-IDF.

6. Análisis exploratorio

6.1. Frecuencias y vocabulario compartido

En desastres, las palabras más frecuentes incluyen *fire* (180), *news* (138), *disaster* (117), *california* (111), *suicide* (110), *killed* (93) y *storm* (85). En no desastres destacan *like* (253), *im* (248), *amp* (193), *new* (170), *get* (163), *dont* (154) y *love* (90). La Figura 1 hace visible la diferencia entre términos de eventos concretos y lenguaje conversacional.




Figura 1: Quince palabras más frecuentes en tweets de desastres y no desastres.

Palabras como *via*, *amp*, *people* y *like* aparecen en ambas clases; una frecuencia alta aislada no basta para discriminar. En contraste, ratios exploratorios suavizados identificaron términos muy inclinados hacia desastres, como *northern*, *legionnaires*, *debris*, *severe* e *hiroshima*, y hacia no desastres, como *bags*, *bag*, *aftershock*, *ruin* y *lmao*. Algunos reflejan eventos o usos metafóricos específicos, por lo que no deben interpretarse como relaciones causales.

El vocabulario contiene 8,006 tipos en desastres y 10,372 en no desastres. Solo 3,805 aparecen en ambas clases; 4,201 son exclusivos del primer grupo y 6,567 del segundo. La Figura 2 resume este solapamiento. Aunque sugiere separabilidad léxica, muchos tipos exclusivos son errores tipográficos, nombres propios o fragmentos poco frecuentes.




Figura 2: Cantidad de palabras compartidas y exclusivas por categoría.

6.2. Nubes de palabras

Las nubes de la Figura 3 corroboran el patrón: la clase de desastre está dominada por vocabulario de emergencia, noticias, lugares e incidentes; la clase no desastre contiene más lenguaje cotidiano y afectivo. Estas visualizaciones resumen frecuencia, pero no corrigen por tamaño de clase ni prueban capacidad predictiva.



Figura 3: Nubes de palabras para tweets de desastres y no desastres.

7. Unigramas, bigramas y trigramas

Los n-gramas se generaron **dentro de cada tweet**. Para un tweet tokenizado como $(w_1, \dots, w_m)$, se enumeraron las ventanas consecutivas $(w_i, \dots, w_{i+n-1})$ y solo después se agregaron sus conteos por clase. Concatenar todos los tweets antes de formar ventanas habría creado secuencias inexistentes entre el final de un tweet y el inicio del siguiente.

Para cada clase c , la frecuencia observada fue $f_c(g)$ y la probabilidad relativa se calculó como

$$\hat{P}(g | c) = \frac{f_c(g)}{\sum_{g'} f_c(g')}.$$

Los conteos y estas probabilidades no recibieron suavizado. El +1 de Laplace se usó únicamente en ratios exploratorios entre clases,

$$R(g) = \frac{f_1(g) + 1}{f_0(g) + 1},$$

para evitar división por cero sin presentar apariciones ficticias como conteos observados.

Cuadro 3: Diversidad y totales observados de n-gramas por clase.

Tipo	Tipos únicos		Total observado	
	Desastre	No desastre	Desastre	No desastre
Unigramas	8,006	10,372	30,342	36,371
Bigramas	19,041	26,901	27,071	32,029
Trigramas	18,153	24,700	23,810	27,757

La Figura 4 muestra que los bigramas aumentan la variedad contextual y que los trigramas únicos disminuyen frente a los bigramas, pues numerosos tweets son cortos. Los totales observados decrecen al aumentar n , como corresponde cuando se respetan los límites documentales.




Figura 4: Cantidad de n-gramas únicos por categoría.

Entre los bigramas de desastre aparecen *suicide bomber* (59), *oil spill* (38), *burning buildings* (35), *suicide bombing* (34) y *california wildfire* (34). En no desastres aparecen secuencias sobre un evento viral de Reddit y lenguaje coloquial como *looks like*, *feel like* y *dont know*. La presencia de *burning buildings* en ambas clases ilustra que el contexto ayuda, pero no elimina la ambigüedad. La comparación se presenta en la Figura 5.




Figura 5: Bigramas más frecuentes en cada categoría.

Los trigramas aportan contexto adicional, pero varios de los más frecuentes son fragmentos de un mismo tweet viral repetido. Por tanto, su frecuencia puede representar duplicación de un evento concreto y no una regla lingüística general. Esta evidencia motivó usar unigramas y bigramas en

TF-IDF: capturan contexto corto con menos dispersión y menor riesgo de memorizar cadenas extensas.

8. Modelos de clasificación

8.1. Configuración

La representación fue TF-IDF de unigramas y bigramas, limitada a 5,000 características. El vectorizador se ajustó solo con entrenamiento. Se compararon:

- **Naive Bayes multinomial**: parámetros predeterminados;
- **regresión logística**: `max_iter=1000`, `random_state=42`;
- **SVM lineal**: `LinearSVC(random_state=42)`.

Las métricas consideran a desastre real como clase positiva. Exactitud resume aciertos globales; precisión cuantifica cuántas alertas positivas son correctas; *recall* cuantifica cuántos desastres reales se detectan; F1 equilibra precisión y *recall* [5, 4].

Cuadro 4: Métricas exactas del conjunto de prueba, extraídas del notebook ejecutado.

Modelo	Exactitud	Precisión	Recall	F1
Naive Bayes	0.812213	0.860784	0.671254	0.754296
Regresión logística	0.822718	0.846570	0.717125	0.776490
SVM lineal	0.795141	0.765528	0.753823	0.759630

La regresión logística se seleccionó por el F1 más alto. Naive Bayes fue el más preciso, pero su *recall* de 0.671254 implica más desastres omitidos. SVM obtuvo el mejor *recall*, a costa de una caída considerable de precisión y exactitud. La regresión logística ofrece el mejor compromiso para un problema donde importan tanto las falsas alarmas como los eventos no detectados.

9. Función de clasificación

La función `clasificar_tweet(texto)` recibe texto crudo, ejecuta `limpiar_tweet`, transforma el resultado con el vectorizador ya ajustado y aplica la regresión logística baseline. El diseño contiene una rama para concatenar VADER solo si el modelo enriquecido supera al baseline; como el experimento del Ejercicio 10 no mostró mejora, esa rama no se selecciona. La salida es “Desastre real” o “No es un desastre”.

Los siguientes son outputs reales guardados en el notebook:

Cuadro 5: Ejemplos de ejecución de la función final.

Tweet crudo	Salida
Forest fire near La Ronge Sask. Canada	Desastre real
I love this weather, going to the beach today!	No es un desastre
BREAKING: earthquake magnitude 7.2 hits the coast, buildings collapsed	Desastre real
This song is fire, best track of the year	No es un desastre

Estos casos comprueban el recorrido técnico y muestran que el modelo distingue un uso literal de *fire* de uno figurado. No sustituyen una evaluación externa con eventos nuevos.

10. Sentimiento con VADER

VADER es un modelo léxico y basado en reglas, diseñado para texto de redes sociales [2]. Para cada tweet produce proporciones **neg**, **neu** y **pos**, además de un puntaje compuesto normalizado. Se aplicaron los umbrales convencionales: compuesto ≥ 0.05 para positivo, ≤ -0.05 para negativo y el intervalo intermedio para neutral [3]. Al conservar el texto original, emoticones y puntuación siguen disponibles para las reglas del método.

Cuadro 6: Distribución exacta de sentimiento VADER.

Sentimiento	Tweets	Porcentaje
Negativo	3,707	48.69 %
Neutral	2,013	26.44 %
Positivo	1,893	24.87 %
Total	7,613	100.00 %

11. Extremos de sentimiento y comparación por categoría

11.1. Diez tweets más negativos

El orden fue determinista: mayor **vader_neg**, luego menor **vader_compound** y finalmente **id** ascendente. Debido a empates léxicos, el décimo registro no necesariamente es sustancialmente distinto del siguiente.

Cuadro 7: Diez tweets con mayor negatividad VADER.

ID	Tweet	Target	Categoría	Neg	Comp.
10689	wreck? wreck wreck wreck wreck wreck wreck wreck wreck wreck wreck wreck?	0	No desastre	1.000	-0.9883
5221	Fatality!	0	No desastre	1.000	-0.6996

Continuación de la Tabla 7

ID	Tweet	Target	Categoría	Neg	Comp.
5224	fatality	0	No desastre	1.000	-0.6705
7400	Obliterated	0	No desastre	1.000	-0.4767
2703	Crushed	0	No desastre	1.000	-0.4215
8589	* Screams *	0	No desastre	1.000	-0.2960
9106	she's a suicide bomb	0	No desastre	0.885	-0.8271
10295	FUCK NUCLEAR WEAPON	0	No desastre	0.851	-0.6908
1302	Damn bloody hot	0	No desastre	0.848	-0.6808
5259	Fatality ????	0	No desastre	0.845	-0.7550

Los diez extremos negativos pertenecen a **target=0**. Esto no contradice la comparación agregada: son casos particulares, muchos muy breves o figurativos, en los que el léxico de VADER asigna toda la masa a negatividad.

11.2. Diez tweets más positivos

El orden fue mayor **vader_pos**, luego mayor **vader_compound** y **id** ascendente.

Cuadro 8: Diez tweets con mayor positividad VADER.

ID	Tweet	Target	Categoría	Pos	Comp.
6769	@Benji_Devos thanks thanks :3	0	No desastre	0.901	0.8442
7680	@panic awesome thanks.	0	No desastre	0.875	0.7906
8759	Super sweet and beautiful :) https://t.co/TUi9uwBvVp	0	No desastre	0.873	0.9300
628	@local_arsonist LMFAO	0	No desastre	0.809	0.6408
24	I love fruits	0	No desastre	0.808	0.6369
33	Love skiing	0	No desastre	0.808	0.6369
935	@Shayoly yes I love it	0	No desastre	0.775	0.7845
2486	We're happily collided :)	0	No desastre	0.767	0.7650
40	Cooooo :)	0	No desastre	0.750	0.4588
9990	@tsunami_esh ESH PLEASE OKAY!	0	No desastre	0.749	0.7147

También los diez extremos positivos pertenecen a **target=0**, lo que concuerda con lenguaje agradecido, afectivo o humorístico fuera de reportes reales de desastre.

11.3. ¿Los tweets de desastre son más negativos?

La variable **negativity** se definió como el componente **neg** de VADER. Como está acotada, contiene numerosos ceros y no se asumió normalidad, se aplicó Mann–Whitney U bilateral a las dos muestras independientes [7, 6]. La prueba evalúa diferencia entre distribuciones, no causalidad.

Cuadro 9: Resumen de negatividad por categoría.

Categoría	n	Media	Mediana	Desv.	Q1	Q3
Desastre real	3,271	0.173582	0.157	0.167870	0.000	0.294
No desastre	4,342	0.132318	0.088	0.159648	0.000	0.231

El resultado fue $U = 8,141,444.5$, $p = 4.00854 \times 10^{-30}$ y efecto rango-biserial 0.1465, calculado como $2U/(n_1n_0) - 1$. Existe evidencia estadística de que las distribuciones difieren y la media es mayor en desastres. Sin embargo, el tamaño de efecto es pequeño: no puede afirmarse que todo tweet de desastre sea más negativo ni que la diferencia sea grande en términos prácticos. El tamaño muestral elevado ayuda a producir un valor p muy pequeño incluso ante separaciones modestas.

12. Reentrenamiento con negatividad

Para el Ejercicio 10, **negativity** es exactamente **vader_neg** calculado desde el tweet original. Se reutilizaron los mismos índices del split 80/20. La matriz TF-IDF, ajustada solo con entrenamiento, se concatenó con una columna dispersa de negatividad para entrenamiento y prueba. VADER es un procedimiento fijo que no aprende del target; no se estimó ningún parámetro con el conjunto de prueba. De este modo se evitó fuga de información.

Cuadro 10: Regresión logística baseline frente al modelo enriquecido.

Configuración	Exactitud	Precisión	Recall	F1
Baseline TF-IDF	0.822718	0.846570	0.717125	0.776490
TF-IDF + negativity	0.822062	0.847550	0.714067	0.775104
Δ (enriquecido – baseline)	-0.000657	+0.000980	-0.003058	-0.001386

La negatividad no mejoró el modelo. Aunque la precisión aumentó 0.000980, el *recall* disminuyó 0.003058 y el F1 pasó de 0.776490 a 0.775104. La reducción de 0.001386 equivale aproximadamente a 0.14 puntos porcentuales. Por el criterio definido antes del experimento, se conserva el baseline.

13. Limitaciones

- **Duplicados y casi duplicados.** En el CSV analizado existen 110 repeticiones exactas de **text** después de la primera aparición y 817 repeticiones de **text_cleaned**. Estas últimas incluyen textos distintos que colapsan a la misma forma normalizada. Un split aleatorio puede colocar mensajes iguales o casi iguales en ambos subconjuntos y sobreestimar generalización.
- **Eventos específicos.** Palabras y trigramas frecuentes reflejan noticias virales concretas. El modelo puede memorizar eventos, personas o lugares en vez de aprender señales transferibles a futuros desastres.

- **Variables poco explotadas.** *keyword* y *location* no se incorporaron al clasificador. La ubicación tiene muchos nulos y formato libre, pero ambas variables podrían aportar información con codificación y validación cuidadosas.
- **Alcance de VADER.** Es un recurso general para redes sociales en inglés; puede fallar ante sarcasmo, jerga, lenguaje noticioso neutral, ambigüedad y nombres propios.
- **Sesgo del conjunto.** Los tweets corresponden a una selección y periodo concretos de la competencia; clase, idioma, plataforma y tópicos no representan necesariamente otros contextos.
- **Significancia frente a relevancia.** El valor p muy pequeño no implica un efecto grande. El rango-biserial de 0.1465 y la falta de mejora del F1 muestran que la diferencia afectiva tiene utilidad predictiva limitada en esta configuración.
- **Selección y evaluación.** Los modelos se compararon en un único conjunto de prueba. Una estimación más rigurosa requeriría validación cruzada para selección y un conjunto final independiente, idealmente separado por evento o por tiempo.

14. Conclusiones

1. **¿Qué vocabulario ayuda a clasificar?** Los términos de incidentes concretos y sus combinaciones cortas son informativos, mientras que palabras compartidas como *via*, *amp* o *people* discriminan poco de forma aislada. Los ratios entre clases son útiles para explorar, pero deben interpretarse con cautela ante términos raros y tweets repetidos.
2. **¿Vale la pena explorar bigramas y trigramas?** Sí. Los bigramas recuperan contexto que los unigramas pierden y justifican TF-IDF 1–2. Los trigramas revelan cadenas de eventos y duplicación, pero son más dispersos y propensos a memorizar tweets virales; por ello no se incorporaron al modelo final.
3. **¿Cuál clasificador se debe conservar?** La regresión logística baseline, porque obtuvo el mayor F1 (0.776490) y el mejor compromiso entre precisión y *recall* en el split común.
4. **¿Los tweets de desastre son más negativos?** En promedio y distribución, sí existe una diferencia estadística: 0.173582 frente a 0.132318 y $p = 4.00854 \times 10^{-30}$. La respuesta práctica debe ser prudente, pues el efecto 0.1465 es pequeño y los extremos individuales no siguen necesariamente la tendencia agregada.
5. **¿La negatividad mejoró la clasificación?** No. El F1 disminuyó 0.001386 y el *recall* también cayó. La señal afectiva existe a nivel grupal, pero está parcialmente contenida en el vocabulario o es demasiado débil y ambigua para aportar al baseline de esta prueba.
6. **¿La función satisface el objetivo operativo?** Sí: recibe un tweet crudo, reproduce la limpieza y vectorización del entrenamiento y devuelve una categoría. Su uso fuera del conjunto debe acompañarse de monitoreo y evaluación con eventos no vistos.

A. Reproducibilidad

Desde la raíz del repositorio:

```
uv sync --locked
uv run jupyter lab Lab5_Completo.ipynb
```

El notebook verifica y descarga los recursos de NLTK cuando son necesarios. Una descarga explícita equivalente es:

```
uv run python -m nltk.downloader stopwords vader_lexicon
```

Para ejecutar todas las celdas y actualizar sus outputs:

```
uv run jupyter nbconvert --to notebook --execute --inplace \
  Lab5_Completo.ipynb
```

Para compilar este informe desde `report/`:

```
/usr/bin/pdflatex -interaction=nonstopmode \
  -jobname=Laboratorio_5_Informe lab5_report.tex
/usr/bin/pdflatex -interaction=nonstopmode \
  -jobname=Laboratorio_5_Informe lab5_report.tex
```

El informe de trabajo y el repositorio están disponibles en <https://github.com/Qu3zada22/lab5-ds>. Este repositorio contiene el código, el notebook, la fuente LaTeX y el PDF compilado.

Referencias

- [1] Kaggle. *Natural Language Processing with Disaster Tweets*. Datos de la competencia. Disponible en: <https://www.kaggle.com/competitions/nlp-getting-started/data>. Consultado el 29 de agosto de 2026.
- [2] Hutto, C. J. y Gilbert, E. (2014). VADER: A Parsimonious Rule-Based Model for Sentiment Analysis of Social Media Text. *Proceedings of the International AAAI Conference on Web and Social Media*, 8(1), 216–225. <https://doi.org/10.1609/icwsm.v8i1.14550>.
- [3] NLTK Project. *NLTK Sentiment VADER API documentation*. Disponible en: <https://www.nltk.org/api/nltk.sentiment.vader.html>. Consultado el 29 de agosto de 2026.
- [4] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830. Disponible en: <https://jmlr.org/papers/v12/pedregosa11a.html>.
- [5] Scikit-learn developers. *Scikit-learn documentation*. Disponible en: <https://scikit-learn.org/stable/>. Consultado el 29 de agosto de 2026.
- [6] SciPy community. *scipy.stats.mannwhitneyu documentation*. Disponible en: <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.mannwhitneyu.html>. Consultado el 29 de agosto de 2026.
- [7] Mann, H. B. y Whitney, D. R. (1947). On a Test of Whether One of Two Random Variables Is Stochastically Larger than the Other. *The Annals of Mathematical Statistics*, 18(1), 50–60. <https://doi.org/10.1214/aoms/1177730491>.
- [8] Virtanen, P. et al. (2020). SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. *Nature Methods*, 17, 261–272. <https://doi.org/10.1038/s41592-019-0686-2>.
- [9] Jurafsky, D. y Martin, J. H. *Speech and Language Processing*, 3.a ed., borrador en línea. Disponible en: <https://web.stanford.edu/~jurafsky/slp3/>. Consultado el 29 de agosto de 2026.
- [10] Jurafsky, D. y Martin, J. H. *N-grams*, material de *Speech and Language Processing*. Disponible en: <https://lagunita.stanford.edu/c4x/Engineering/CS-224N/asset/slp4.pdf>.
- [11] Feinerer, I., Hornik, K. y Meyer, D. (2008). Text Mining Infrastructure in R. *Journal of Statistical Software*, 25(5), 1–54. <https://doi.org/10.18637/jss.v025.i05>.